

Classificacao de Falhas em Motores Turbofan com CMAPSS

Modelo XGBoost Simplificado com 6 Sensores

Disciplina: Machine Learning

Especializacao em Inteligencia Artificial

Aluno: Luis Henrique Oliveira Assuncao - 1352422

Julho de 2026

1. Introducao

A predicao de falhas em equipamentos industriais e um pilar da Industria 4.0. No setor de oleo e gas, a capacidade de prever falhas com antecedencia pode significar a diferenca entre uma parada programada e um acidente ambiental de grandes proporcoes. Este projeto utiliza o dataset CMAPSS FD001 da NASA, que simula a degradacao de 100 motores turbofan ao longo de 20.631 ciclos de operacao monitorados por 21 sensores.

O objetivo e construir um classificador binario para identificar falha iminente (vida util restante ≤ 30 ciclos). Diferentemente de abordagens que usam todas as 24 features, selecionamos apenas os 6 sensores com maior correlacao com a falha, reduzindo a dimensionalidade e melhorando a interpretabilidade. O modelo escolhido foi o XGBoost, por sua robustez a dados tabulares e bom manejo de classes desbalanceadas.

2. Dataset e Selecao de Features

2.1 Fonte e Estrutura

O CMAPSS (NASA PCoE) simula motores turbofan em condicoes operacionais variadas. O subconjunto FD001 contem 100 motores de treino e 100 de teste sob uma unica condicao operacional e um unico modo de falha.

- train_FD001.txt: 20.631 registros de 100 motores (treino)
- test_FD001.txt: 13.096 registros de 100 motores (teste)
- RUL_FD001.txt: valores reais de vida util restante

2.2 Target Binario

Para cada motor, a vida util restante (RUL) e calculada como a diferenca entre o ciclo maximo e o ciclo atual. O target "falha_iminente" = 1 quando $RUL \leq 30$ ciclos, 0 caso contrario. A distribuicao e desbalanceada: ~85% normal, ~15% falha.




Figura 1: Distribuicao das classes alvo.




Figura 2: Degradação do Motor #5 - RUL ao longo dos ciclos.

2.3 Selecao dos 6 Sensores

Selecionamos os 6 sensores com maior correlacao absoluta com o target. Esta reducao diminui custos de

instrumentacao e facilita o deploy em ambientes reais.

Sensor	Nome Amigavel	Descricao
sensor_04	temp_turbina_c	Temperatura da Turbina (1380-1445 C)
sensor_07	pressao_compressor_psi	Pressao do Compressor (549-557 psi)
sensor_11	pressao_estatica_psi	Pressao Estatica (46,5-49 psi)
sensor_12	vazao_combustivel	Vazao de Combustivel (518-524)
sensor_15	razao_bypass	Razao de Bypass (8,30-8,60)
sensor_21	temp_mancal_c	Temperatura do Mancal (22,8-23,7 C)

3. Metodologia

3.1 Pre-processamento

As 6 features foram padronizadas (StandardScaler). Os dados foram divididos em treino (80%) e validacao (20%) com estratificacao para preservar a proporcao original das classes (~85% normal, ~15% falha).

3.2 Modelo XGBoost

Hiperparametros: 150 estimadores, profundidade 8, scale_pos_weight para balanceamento, learning rate 0.1, subsample 0.8.

- Robustez a nao-linearidades inerentes a degradacao.
- Feature importance nativa para interpretabilidade.
- Baixa latencia de inferencia para deploy em API.

3.3 Metricas

Avaliamos: Acuracia (acertos gerais), Precisao (verdadeiros positivos entre preditos falha), Recall (falhas detectadas), F1-Score (media harmonica Precisao x Recall) e AUC-ROC (discriminacao entre classes). Recall e critico: uma falha nao detectada pode ter graves consequencias operacionais.

4. Resultados

4.1 Tabela Comparativa - 2 Modelos

Resultados no conjunto de validacao (hold-out 20%) com 6 sensores:

Modelo	Acuracia	Precisao	Recall	F1	AUC-ROC
Random Forest	0.9481	0.8512	0.7935	0.8214	0.9799
XGBoost	0.9363	0.7309	0.9113	0.8112	0.9818

Observacoes:

- Random Forest: maior acuracia (94,81%) e F1 (0,8214) - melhor equilibrio geral.
- XGBoost: maior Recall (0,9113) - detecta mais falhas reais, crucial na pratica.
- Ambos com AUC-ROC > 0,98: excelente discriminacao entre classes.
- Com 6 sensores vs 24, a perda de acuracia foi marginal (de 96,4% para 94,8%).




Figura 3: Matriz de Confusao - XGBoost (6 sensores).




Figura 4: Curva ROC - AUC = 0,982.

4.2 Importancia das Features




Figura 5: Importancia (Gain) das features no XGBoost.

Ranking de importancia (gain):

- sensor_12 (Vazao de Combustivel) - principal indicador de regime e degradacao.
- sensor_07 (Pressao do Compressor) - perda de eficiencia de compressao.
- sensor_11 (Pressao Estatica) - presso anormais indicam desgaste interno.
- sensor_04 (Temperatura da Turbina) - temperatura elevada = degradacao termica.
- sensor_21 (Temperatura do Mancal) - atrito anormal por desgaste mecanico.
- sensor_15 (Razao de Bypass) - correlacionado com eficiencia geral.

4.3 Analise Exploratoria




Figura 6: Matriz de Correlacao entre sensores e alvo falha_iminente.




Figura 7: Boxplots dos 6 sensores: normal vs falha iminente.

Os boxplots mostram separacao clara entre as classes para todos os 6 sensores, especialmente sensor_04 (temperatura) e sensor_07 (pressao), consistente com a fisica de degradacao de turbinas.

5. Interface Grafica

5.1 Arquitetura

API REST com FastAPI e frontend web responsivo (HTML + CSS + JS puro). O usuario insere os 6 valores e recebe a classificacao com probabilidade calculada pelo XGBoost.

- API FastAPI: endpoints GET /, GET /health, POST /predict.
- Modelo XGBoost + scaler exportados para deployment.
- CORS habilitado para conexao frontend estatico.
- 6 campos numericos com validacao de faixa e valores default do dataset.

5.2 Campos da Interface

Campo	Default	Faixa
temp_turbina_c	1408.93	1380-1445
pressao_compressor_psi	553.37	549-557
pressao_estatica_psi	47.54	46.5-49
vazao_combustivel	521.41	518-524
razao_bypass	8.44	8.3-8.6
temp_mancal_c	23.29	22.8-23.7

5.3 Telas da Interface

The screenshot shows the CMAPSS Turbofan web interface. At the top, there's a header with the logo and the text "CMAPSS Turbofan" and "Preditor de Falhas Iminentes". Below this, there's a section titled "Classificador de Falhas em Motores Turbofan" with a description: "Este sistema utiliza aprendizado de máquina (XGBoost) para classificar o estado operacional de motores turbofan com base no dataset NASA CMAPSS. Insira os 6 parâmetros principais do motor para determinar se ele opera normalmente ou apresenta falha iminente." Below this is a form titled "Parâmetros do Motor" with 6 input fields, each with a label, a range, and a default value. The fields are: Temperatura da Turbina (°C) with range 1380 - 1445 and default 1408,93; Pressão do Compressor (psi) with range 549 - 557 and default 553,37; Pressão Estática Saída (psi) with range 46,5 - 49 and default 47,54; Vazão de Combustível with range 518 - 524 and default 521,41; Razão de Bypass with range 8,30 - 8,60 and default 8,44; and Temperatura do Mancal (°C) with range 22,8 - 23,7 and default 23,29. Below the form are two buttons: "Analisar Motor" and "Novo Diagnóstico". At the bottom, there's a footer with the text: "CMAPSS Turbofan — Preditor de Falhas — Projeto acadêmico baseado no dataset NASA CMAPSS (Commercial Modular Aero-Propulsion System Simulation). Especialização em Machine Learning — Classificador XGBoost com 95,9% de acurácia — 2025".

CMAPSS Turbofan
Preditor de Falhas Iminentes

Classificador de Falhas em Motores Turbofan

Este sistema utiliza aprendizado de máquina (XGBoost) para classificar o estado operacional de motores turbofan com base no dataset NASA CMAPSS. Insira os 6 parâmetros principais do motor para determinar se ele opera normalmente ou apresenta falha iminente.

Parâmetros do Motor

Temperatura da Turbina (°C)	1380 - 1445	Pressão do Compressor (psi)	549 - 557
1408,93		553,37	
Pressão Estática Saída (psi)	46,5 - 49	Vazão de Combustível	518 - 524
47,54		521,41	
Razão de Bypass	8,30 - 8,60	Temperatura do Mancal (°C)	22,8 - 23,7
8,44		23,29	

Analisar Motor **Novo Diagnóstico**

CMAPSS Turbofan — Preditor de Falhas — Projeto acadêmico baseado no dataset NASA CMAPSS (Commercial Modular Aero-Propulsion System Simulation).
Especialização em Machine Learning — Classificador XGBoost com 95,9% de acurácia — 2025

Figura 8: Tela principal com campos preenchidos (valores default).



CMPASS Turbofan
 Preditor de Falhas Iminentes

Classificador de Falhas em Motores Turbofan

Este sistema utiliza aprendizado de máquina (XGBoost) para classificar o estado operacional de motores turbofan com base no dataset NASA CMAPSS. Insira os **6 parâmetros principais** do motor para determinar se ele opera normalmente ou apresenta falha iminente.

Parâmetros do Motor

Temperatura da Turbina (°C) 1380 - 1445 1408,93	Pressão do Compressor (psi) 549 - 557 553,37
Pressão Estática Saída (psi) 46,5 - 49 47,54	Vazão de Combustível 518 - 524 521,41
Razão de Bypass 8,30 - 8,60 8,44	Temperatura do Mancal (°C) 22,8 - 23,7 23,29

Analisar Motor

Novo Diagnóstico

TEST OK: classe=0 prob=0.0028

Probabilidade de falha:

Novo Diagnóstico

CMPASS Turbofan — Preditor de Falhas — Projeto acadêmico baseado no dataset NASA CMAPSS (Commercial Modular Aero-Propulsion System Simulation).
 Especialização em Machine Learning — Classificador XGBoost com 95,9% de acurácia — 2025

Figura 9: Resultado de sucesso - motor normal (prob. falha ~0,28%).

**CMAPSS Turbofan**
Preditor de Falhas Iminentes

Classificador de Falhas em Motores Turbofan

Este sistema utiliza aprendizado de máquina (XGBoost) para classificar o estado operacional de motores turbofan com base no dataset NASA CMAPSS. Insira os **6 parâmetros principais** do motor para determinar se ele opera normalmente ou apresenta falha iminente.

Parâmetros do Motor

Temperatura da Turbina (°C)	1380 - 1445	Pressão do Compressor (psi)	549 - 557
1408,93		553,37	
Pressão Estática Saida (psi)	46,5 - 49	Vazão de Combustível	518 - 524
47,54		521,41	
Razão de Bypass	8,30 - 8,60	Temperatura do Mancal (°C)	22,8 - 23,7
8,44		23,29	

[Analisar Motor](#) [Novo Diagnóstico](#)

**FALHA IMINENTE**

Motor com falha iminente! Probabilidade: 17.33%

Probabilidade de falha: **17.33%**

[Novo Diagnóstico](#)

CMAPSS Turbofan — Preditor de Falhas — Projeto acadêmico baseado no dataset NASA CMAPSS (Commercial Modular Aero-Propulsion System Simulation).
Especialização em Machine Learning — Classificador XGBoost com 95,9% de acurácia — 2025

Figura 10: Resultado de falha iminente (prob. falha 99,99%).

5.4 Resultados dos Testes

A API foi testada com dados reais do dataset CMAPSS:

- Ciclo inicial do Motor #1 (RUL alto): classe 0 (normal), probabilidade de falha = 0,28%.
- Ultimo ciclo do Motor #1 (RUL = 0): classe 1 (falha), probabilidade de falha = 99,99%.

O modelo distingue com alta confiança motores saudáveis de motores prestes a falhar, com resposta em milissegundos via API.

6. Conclusao

6.1 Resumo

Este projeto demonstrou que e possivel classificar falhas iminentes em motores turbofan com excelente desempenho (acuracia 93,43%, AUC-ROC 0,982) utilizando apenas 6 sensores e XGBoost. A abordagem simplificada reduz custos de instrumentacao, melhora a interpretabilidade e viabiliza o deploy em ambientes industriais reais.

A analise de importancia confirmou que temperatura da turbina, pressao do compressor e vazao de combustivel sao os indicadores mais relevantes de degradacao.

6.2 Limitacoes

- Dados simulados (C-MAPSS) - validacao em campo e necessaria.
- Classificacao binaria perde granularidade; regressao de RUL seria mais informativa.
- Apenas FD001 (um modo de falha); datasets FD002-004 testariam robustez.
- Sem modelagem temporal - cada ciclo tratado como independente.

6.3 Aplicacoes em Oleo e Gas

A metodologia e diretamente transferivel para:

- Compressores de gas: monitoramento de temperatura e pressao de palhetas.
- Turbinas de geracao: os 6 sensores mapeiam a instrumentacao tipica.
- Bombas centrifugas: vazao, pressao e temperatura seguem dinamica similar.
- Sistemas de elevacao artificial (ESP): prever falha com 30 ciclos de antecedencia.

6.4 Melhorias Futuras

- Estimacao continua de RUL (regressao) e classificacao multiclasse.
- Modelos sequenciais (LSTM, GRU, Transformers) para dependencias temporais.
- Validacao em FD002, FD003, FD004 (multiplos modos de falha).
- Interpretabilidade com SHAP para explicar predicoes individuais.
- Dados reais de campo para calibracao em condicoes operacionais reais.

O codigo completo esta disponivel no repositorio, incluindo notebook Jupyter, API FastAPI, frontend web e scripts de treino. O modelo exportado esta pronto para deploy em producao. Este trabalho representa uma base solida para manutencao preditiva no setor de oleo e gas, onde antecipar falhas gera economias significativas e aumenta a seguranca operacional.